EDA_단변량_분석

EDA 단변량 분석

> 기준 데이터: `[PBT] 스킨케어 크림_모델링 전 데이터셋 전처리_EDA_변수선택.ipynb`의 최신 실행 결과

EDA 단변량 분석

- 입력 데이터셋: 토픽분류 결과 데이터셋
- 데이터 타입 변환: `국가`, `제품_순위` 컬럼을 category 타입으로 변환
- 데이터 중복 점검: 중복된 행 0건
- 중복 점검 후 데이터: **7,230행 × 14열**

불필요한 컬럼 제거

컬럼	처리
`리뷰_번호`	행마다 고유한 ID이므로 모델링 피처에서 제외
`별점`	`Y`가 별점에서 파생된 값이므로 피처로 사용할 경우 데이터 누수 발생 → 제외

실제 결측치 및 토픽 미매칭 리뷰 점검

실제 결측치는 **0건**이었다.

9개 토픽(`보습`, `향`, `발림성`, `자극`, `용기`, `배송`, `기능`, `가격`, `브랜드충성도`)이 모두 0인 행은 일반적인 결측치가 아니라 **토픽 사전에 매칭되지 않은 리뷰**로 보고 분석 대상에서 제외하였다.

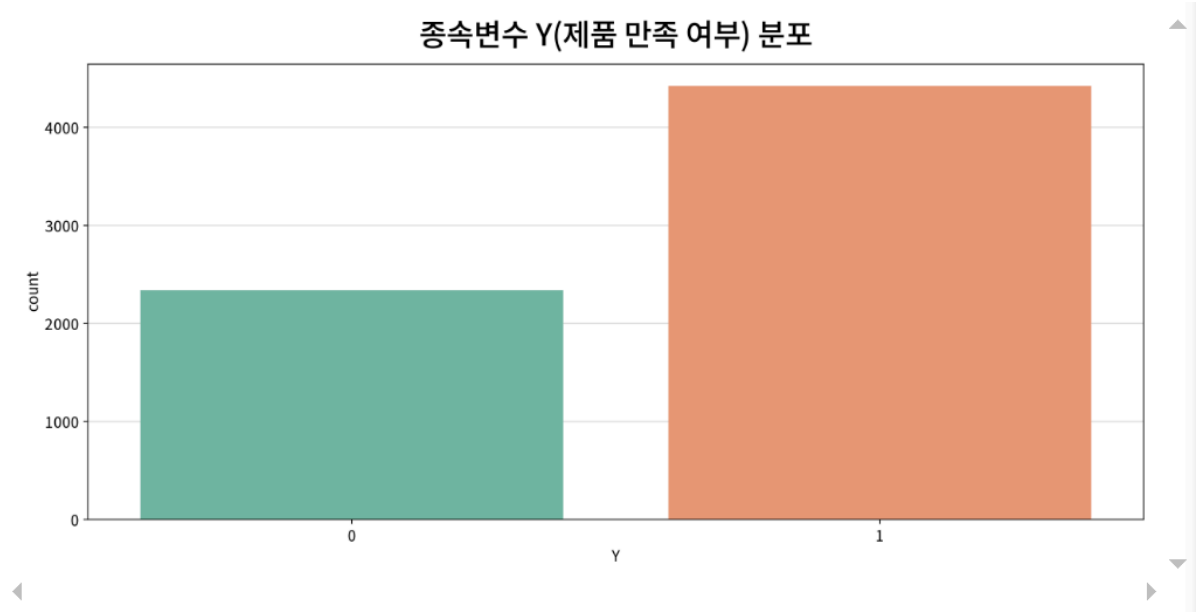
- 9개 속성값이 모두 0인 행: **474건**
- 국가별 전체 0행
  - 러시아: **234건**
  - 한국: **107건**
  - 미국: **89건**
  - 일본: **44건**
- 삭제 전: **7,230건**
- 삭제 후: **6,756건**

- 제외된 리뷰: **474건**

명목형 독립변수 단변량 분석

구분	단변량 분석	이변량 분석
보는 변수 수	1개	2개
목적	각 변수의 분포 확인	두 변수 간 관계 확인
예시	보습이 0/1로 얼마나 분포하는가	보습과 Y가 관련 있는가
주요 결과	빈도, 비율, 불균형	만족률 차이, χ^2, p-value, Cramer's V
질문	"보습 언급 리뷰가 얼마나 많지?"	"보습 언급 여부에 따라 만족도가 달라지나?"

종속변수 Y



Y	빈도	비율
1	4420	0.654233
0	2336	0.345767

점검항목	제품 만족도 관찰값
범주 수	2 (`0=불만족` , `1=만족`)
최빈 범주	만족 **4,420건 (65.4%)**
최소 범주	불만족 **2,336건 (34.6%)**

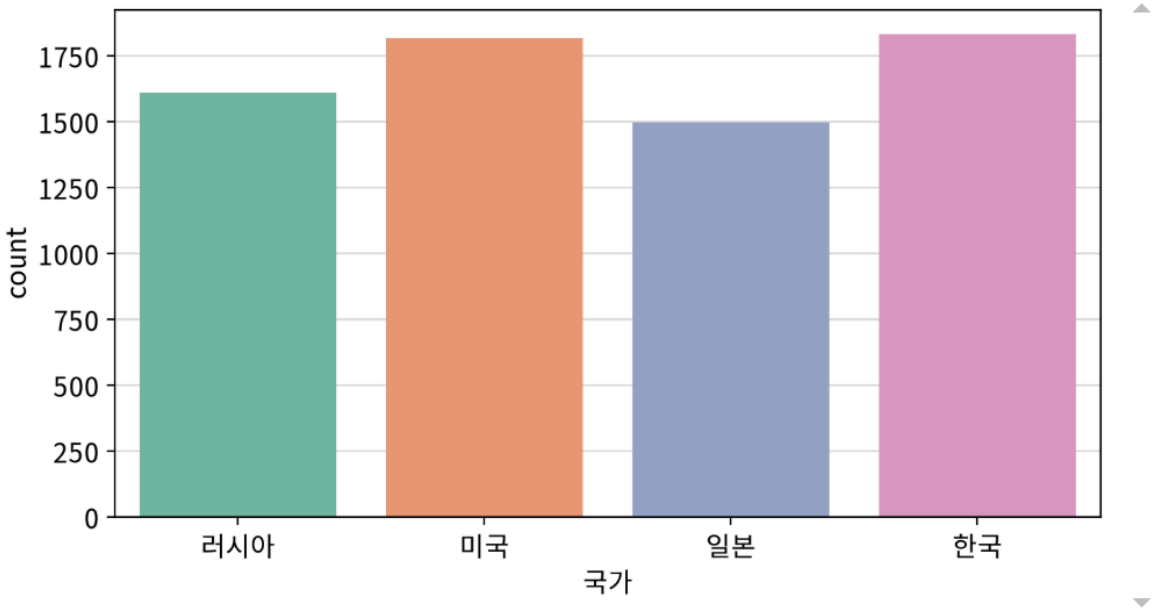
점검항목	제품 만족도 관찰값
균형 여부	약간 불균형 (**65:35**)

- 정확도의 단순 기준선은 65.4%이다.
- 모든 리뷰를 "만족"으로만 예측해도 약 65.4%의 정확도가 나온다.
- 따라서 정확도 70%는 기준선보다 약 **4.6%p** 높은 수준에 불과하다.
- 클래스 비율이 약 65:35이므로 정확도만 보지 않고 F1, Recall, Precision, MCC, AUC 등도 함께 확인하는 것이 적절하다.

국가

▶ 국가 (리뷰 작성 국가) 분포

국가	한국	미국	러시아	일본
빈도	1832.000000	1818.000000	1608.000000	1498.000000
비율	0.271166	0.269094	0.238011	0.221729



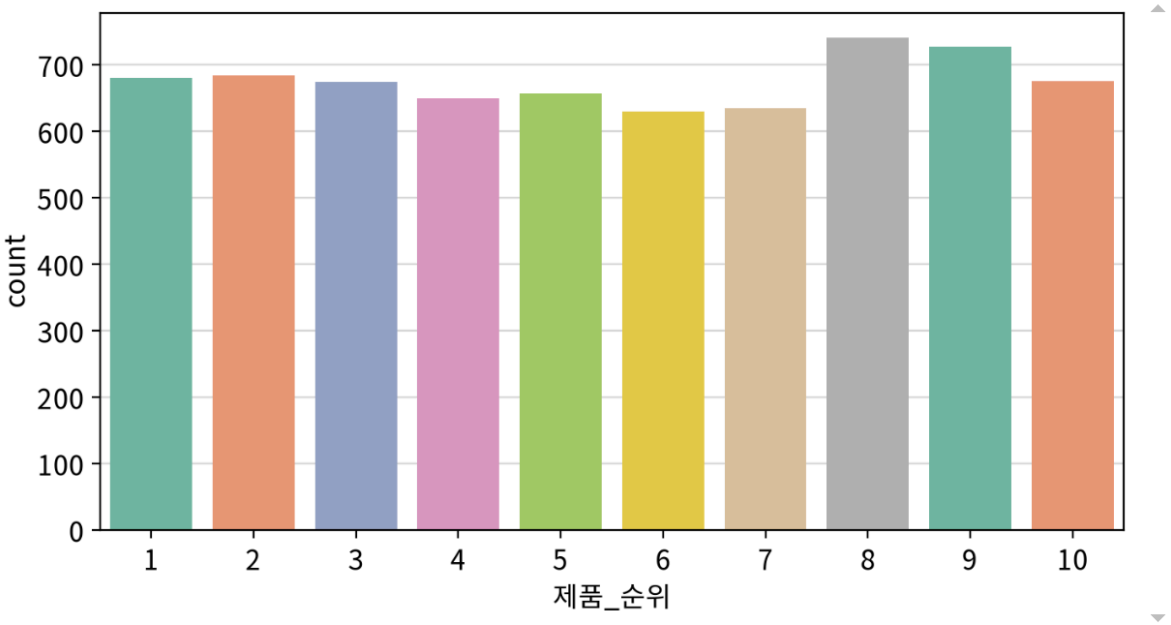
- 한국: **1,832건 (27.1%)**
- 미국: **1,818건 (26.9%)**
- 러시아: **1,608건 (23.8%)**
- 일본: **1,498건 (22.2%)**

판단: 네 국가의 표본 수는 약 22~27% 범위로 비교적 고르게 분포한다. 다만 국가별 만족률 자체는 수집 설계의 영향을 받을 수 있으므로 국가 간 소비자 만족도를 직접 비교하는 근거로 사용하지 않는다.

제품_순위

▶ 제품_순위 (국가별 제품 순위) 분포

제품_순위	8	9	2	1	10	3	5	4	7	6
빈도	741.00000	728.000000	684.000000	681.000000	676.000000	674.000000	657.000000	650.000000	635.000000	630.00000
비율	0.10968	0.107756	0.101243	0.100799	0.100059	0.099763	0.097247	0.096211	0.093991	0.09325



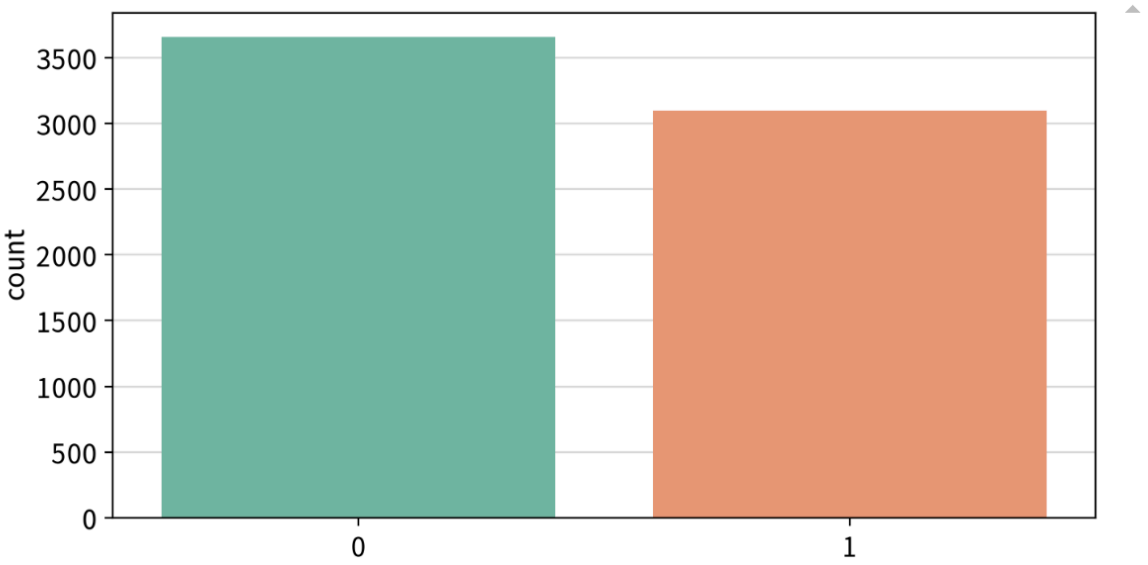
- 8위: **741건 (11.0%)**
- 9위: **728건 (10.8%)**
- 2위: **684건 (10.1%)**
- 1위: **681건 (10.1%)**
- 10위: **676건 (10.0%)**
- 3위: **674건 (10.0%)**
- 5위: **657건 (9.7%)**
- 4위: **650건 (9.6%)**
- 7위: **635건 (9.4%)**
- 6위: **630건 (9.3%)**

판단: 10개 범주가 약 9.3~11.0% 범위로 고르게 분포하며, 특정 제품 순위로 심하게 쏠리는 현상은 확인되지 않았다.

보습

▶ 보습 (보습 속성 언급 여부) 분포

보습	0	1
빈도	3657.000000	3099.000000
비율	0.541297	0.458703

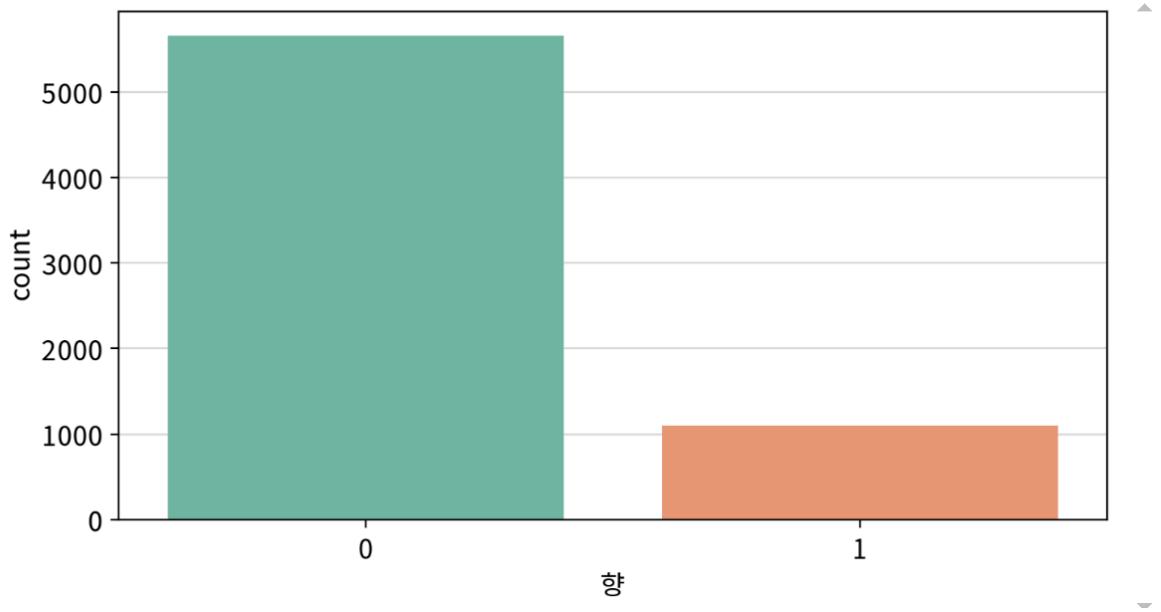


- 범주 수: 2 (`0=미언급` , `1=언급`)
- 미언급: **3,657건 (54.1%)**
- 언급: **3,099건 (45.9%)**

판단: 약 54:46으로 비교적 균형적인 이진 분포이다.

향

향	0	1
빈도	5657.00000	1099.00000
비율	0.83733	0.16267



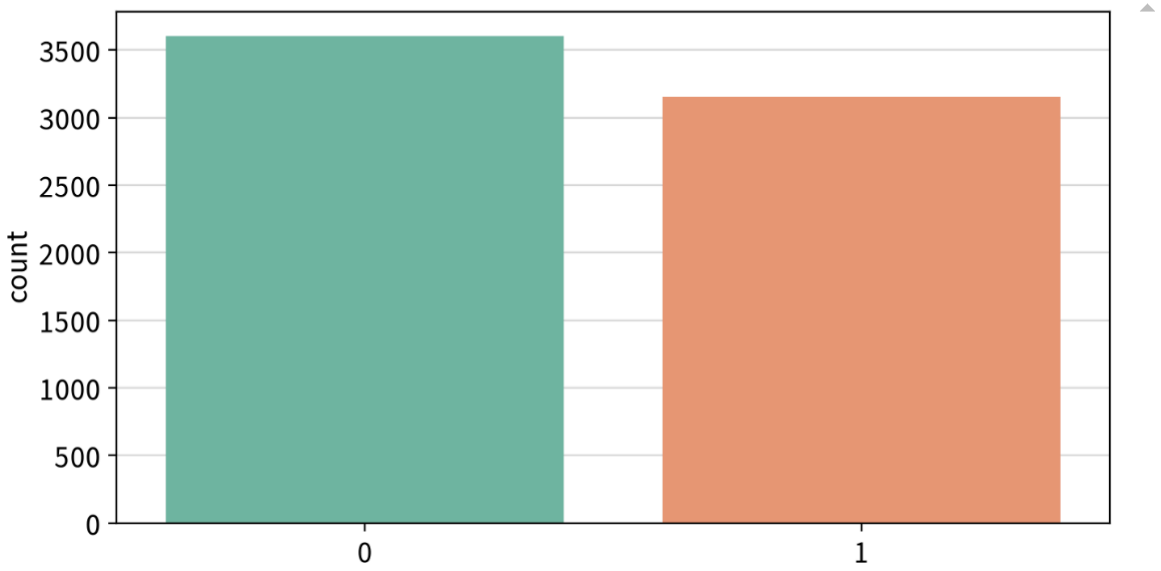
- 미언급: **5,657건 (83.7%)**
- 언급: **1,099건 (16.3%)**

판단: 미언급이 약 84%로, 향 언급 리뷰가 상대적으로 적은 불균형 분포이다.

발림성

▶ 발림성 (발림성 속성 언급 여부) 분포

발림성	0	1
빈도	3603.000000	3153.000000
비율	0.533304	0.466696



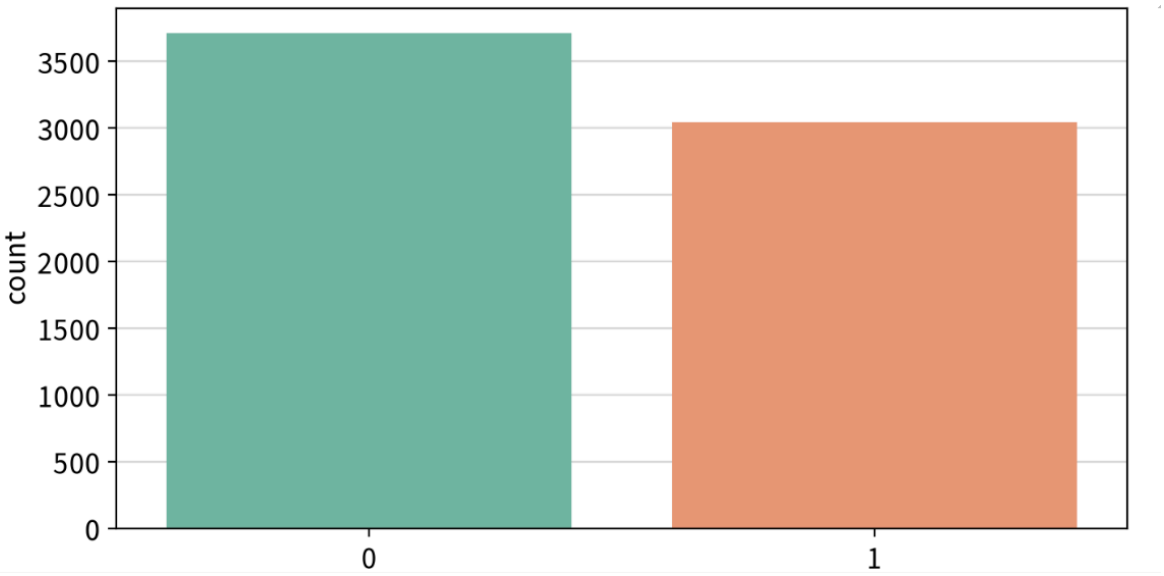
- 미언급: **3,603건 (53.3%)**
- 언급: **3,153건 (46.7%)**

판단: 약 53:47로 비교적 균형적인 이진 분포이다.

자극

▶ 자극 (자극 속성 언급 여부) 분포

자극	0	1
빈도	3712.000000	3044.000000
비율	0.549438	0.450562



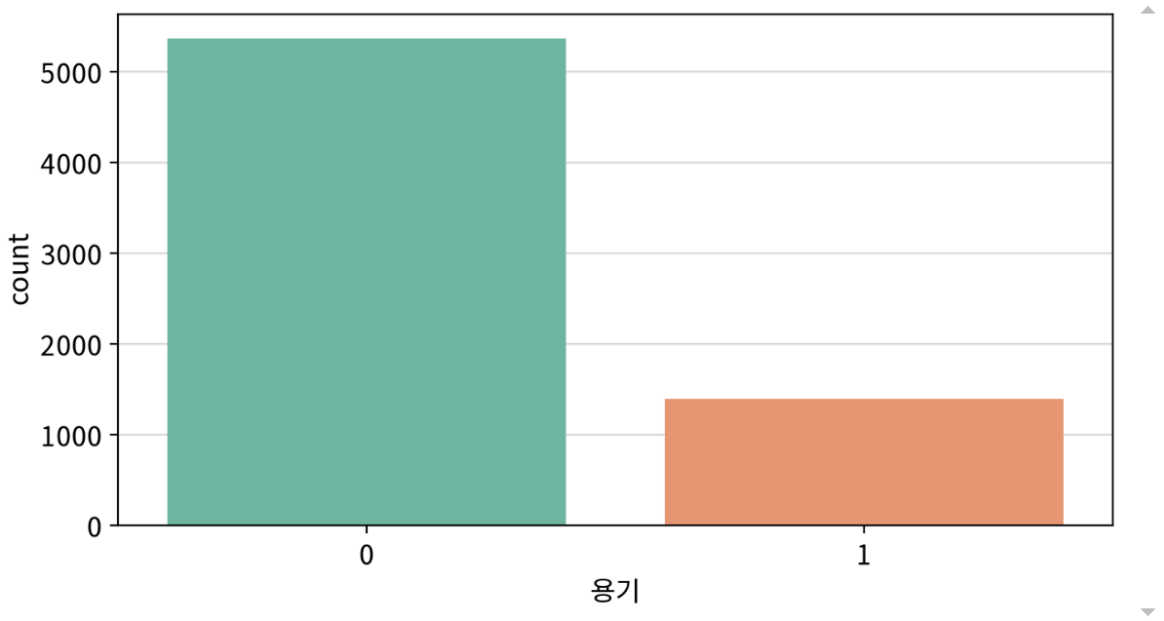
- 미언급: **3,712건 (54.9%)**
- 언급: **3,044건 (45.1%)**

판단: 약 55:45로 비교적 균형적인 분포이다.

용기

▶ 용기 (용기 속성 언급 여부) 분포

용기	0	1
빈도	5364.000000	1392.000000
비율	0.793961	0.206039



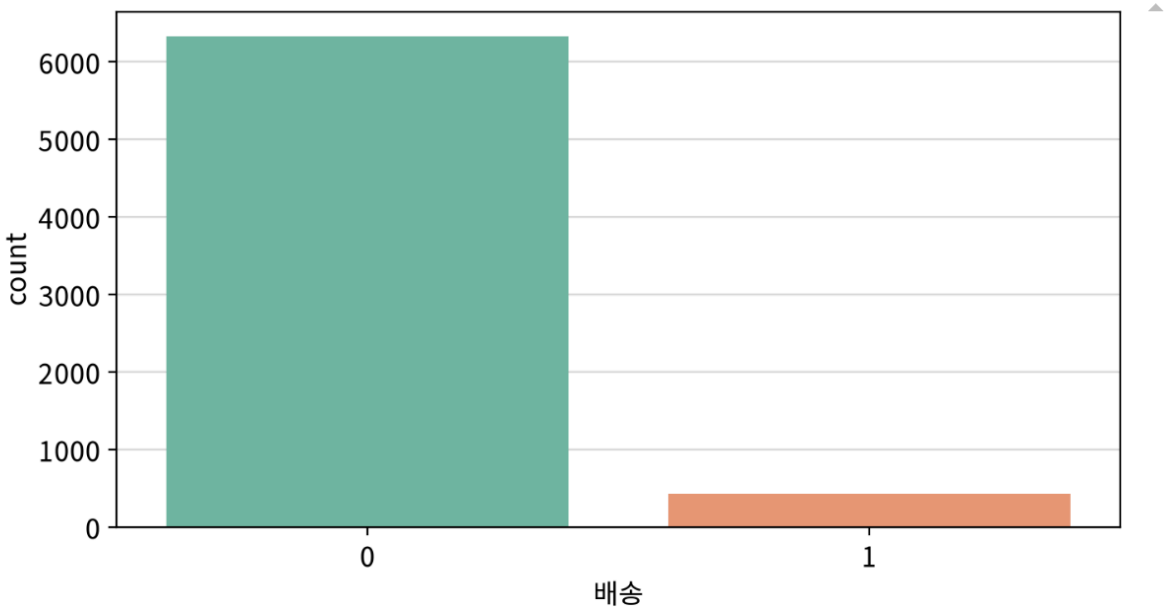
- 미언급: **5,364건 (79.4%)**
- 언급: **1,392건 (20.6%)**

판단: 약 79:21로, 용기 언급 리뷰가 소수인 불균형 분포이다.

배송

▶ 배송 (배송 속성 언급 여부) 분포

배송	0	1
빈도	6329.000000	427.000000
비율	0.936797	0.063203



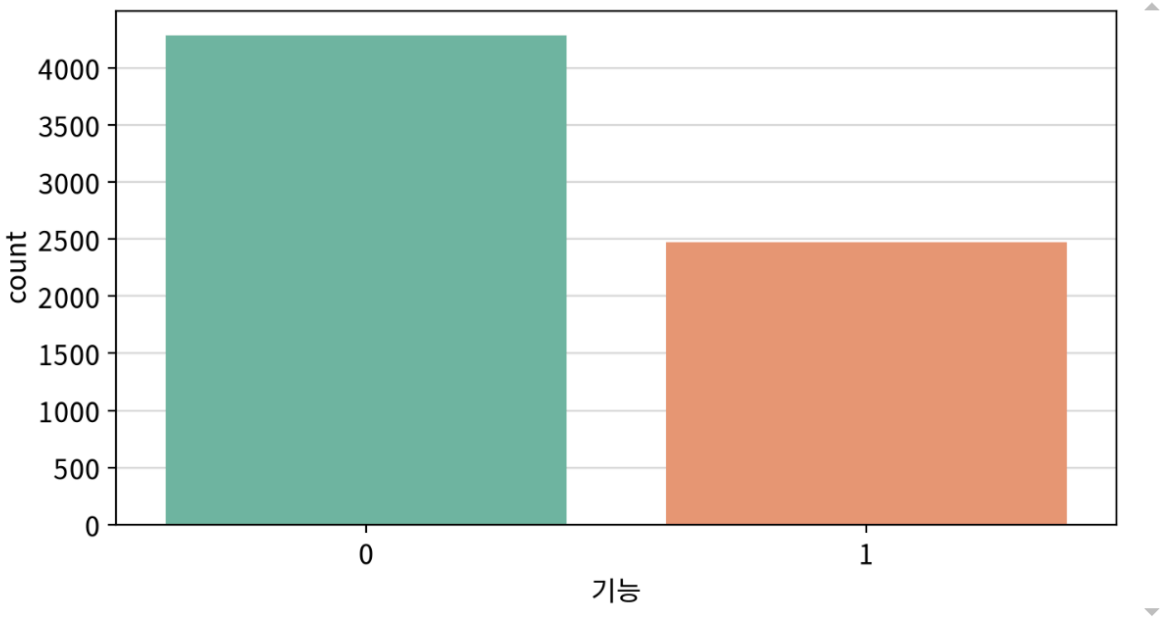
- 미언급: **6,329건 (93.7%)**
- 언급: **427건 (6.3%)**

판단: 약 94:6으로, 배송 언급 리뷰가 매우 적은 심한 불균형 분포이다.

기능

▶ 기능 (기능 속성 언급 여부) 분포

기능	0	1
빈도	4284.000000	2472.000000
비율	0.634103	0.365897



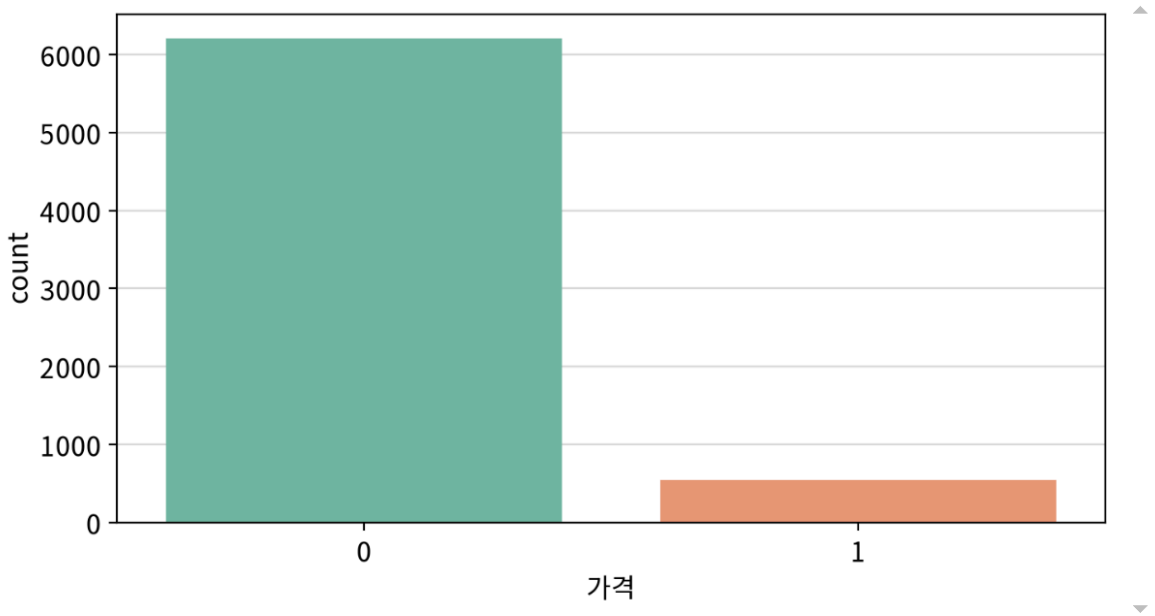
- 미언급: **4,284건 (63.4%)**
- 언급: **2,472건 (36.6%)**

판단: 약 63:37로 미언급 비중이 더 높지만, 두 범주 모두 충분한 관측치가 확보된 분포이다.

가격

▶ 가격 (가격 속성 언급 여부) 분포

가격	0	1
빈도	6208.000000	548.000000
비율	0.918887	0.081113



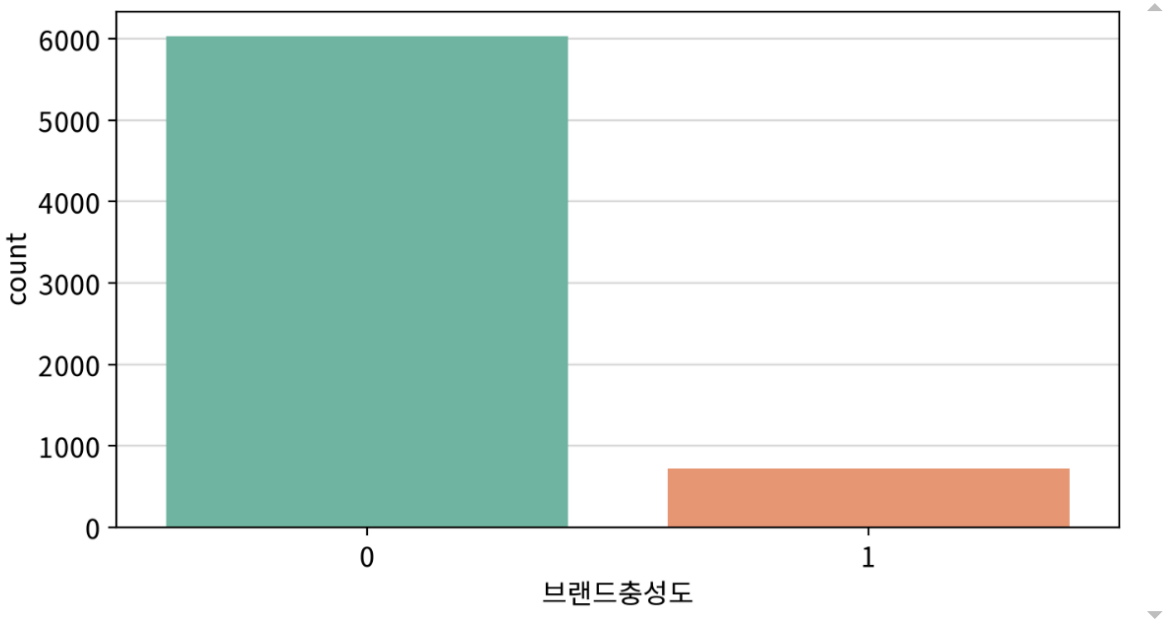
- 미언급: **6,208건 (91.9%)**
- 언급: **548건 (8.1%)**

판단: 약 92:8로, 가격 언급 리뷰가 매우 적은 심한 불균형 분포이다.

브랜드충성도

▶ 브랜드충성도 (브랜드 충성도 언급 여부) 분포

브랜드충성도	0	1
빈도	6033.000000	723.000000
비율	0.892984	0.107016



- 미언급: **6,033건 (89.3%)**
- 언급: **723건 (10.7%)**

판단: 약 89:11로, 브랜드충성도 언급 리뷰가 소수인 불균형 분포이다.

단변량 분석 요약

최신 토픽 분류 결과 적용 후 최종 분석 대상은 **6,756건**이다.

보습·발림성·자극은 비교적 균형적인 분포를 보였으며, 향·용기·배송·가격·브랜드충성도는 언급 비율이 상대적으로 낮았다. 기능은 미언급 63.4%, 언급 36.6%로 이전보다 언급 비중이 낮아졌으나 두 범주 모두 충분한 관측치를 확보하였다.